

Logistische Regressie

Vervoort Kobe

Keustermans Jimmy

Keuze notebook

- Geeft een **overzicht** van **Logistische** Regressie en **Lineaire** Regressie
- Notebook maakt classificatie van financiële gegevens
- Zet Logistische Regressie in een **ML context**
 - Cross-Validation
 - Confusion Matrices
 - Sensitivity & Specificity
 - ROC/AUC

Logistische Regressie

- **Lineaire** Regressie: **voorspellen** van waardes
- **Logistische** Regressie: **classificatie**
- Fundament voor Logistische Regressie:
 - Sigmoid
 - Odds
 - Logit functie / $\text{Log}(\text{odds})$
 - Transformaties (Linearisatie / $\text{Log}(\text{odds})$ naar kans)

Odds vs Probability

- **Probability: kans** dat er iets gebeurd
 - Vb. 80% kans dat Team A wint van Team B
- **Odds: kansverhouding**
 - Kans dat iets gebeurd vs kans dat er niets gebeurd
 - Vb. 5 kansen tov 3 dat Team A wint van Team B

Log van Odds

- **Probleem** met Odds

- Odds Team A wint van Team B

- 2 tegen 1 = 2 vs 1 tegen 2 = 0.5
 - 4 tegen 1 = 4 vs 1 tegen 4 = 0.25
 - 6 tegen 1 = 6 vs 1 tegen 6 = 0.167
 - 10 tegen 1 = 10 vs 1 tegen 10 = 0.1


- **Asymmetrie** ☹️



Log van Odds

- We zien **verschil in magnitude**
 - **Ongewenste situatie**, algoritmes in ML prefereren symmetrie (en wiskundigen ook ;))
 - **Oplossing: logaritme** = $\log_e(\text{odds}) = \ln(\text{odds})$
 - Voorbeeld: 6 tegen 1 en 1 tegen 6
 - $\ln(6) = +1.79$
 - $\ln(1/6) = -1.79$
 - $(\ln(e^x) = x = \text{inverse van functie van } e^x)$

SYMMETRIE! 😊




Log(odds) binnen Logistische Regressie

- log(odds)
 - Odds
 - **Kans** dat er iets gebeurt tov. dat er niets gebeurt
 - Kans dat er **iets gebeurt**: $p(x)$
 - Kans dat er **niets gebeurt**: $1 - p(x)$
 - log = verkrijgen van symmetrie
 - **Basistransformatie** Logistische Regressie
 - $\log(\text{odds}) = \log(p(x) / (1 - p(x)))$

Classificatie

- Classificatie = **kans** tussen 0 en 1
 - Vb. wat is de kans dat iemand met een bepaald cholesterolgehalte een vaatziekte heeft?
 - Rechte lijn voor classificatie?




Mogelijke oplossingen

- **Waarom geen gewone rechte lijn?**
 - Kans kan groter zijn dan 1 of kleiner dan 0
 - Outliers op x-as trekken rechte snel scheef
 - ...
- **Waarom geen afgeplatte lijn aan beide kanten?**
 - Geen onderscheid in kans meer vanaf bepaald punt
 - Moeilijk te lineariseren
- **Empirie stelt dat Sigmoide voor veel gevallen goede afspiegeling is voor classificatie**

Oplossing: Sigmoide

- $y = \log(p / 1 - p)$
- x-as = cholesterolgehalte
 - Als $y < 0.5$
 - Dan geen vaatziekte
 - Anders vaatziekte
- Punten geven realiteit aan
 - Vb. paar punten < 0.5 die toch vaatziekte waren



Logistische Regressie (Conceptueel)

- We hebben Sigmoides gedefinieerd maar deze is niet lineair
 - **Probabiliteit** zodus waarden zijn **beperkt van 0 tot 1**
- We willen **lineariseren** om **technieken uit lineaire regressie** toe te kunnen passen (p-waarde, ANOVA, Multipele Regressie,...)
- Echter:
 - **Lineair model $a + bx$** kan gaan van $-\infty$ tot $+\infty$
 - Probleem: onze **Sigmoides** heeft slechts een **bereik van 0 tot 1**
- Verloop transformaties:
 - Stap 1: van **kans** naar **log-odds**
 - We rekken de kans uit naar een bereik van $-\infty$ tot $+\infty$
 - Symmetrie via $\ln()$ ($\log(\text{odds})$)
 - Stap 2: **lineair model** toepassen
 - Lineariseren van de $\log(\text{odds})$
 - Stap 3: terug naar **kans** converteren
- Essentie: manier om niet-lineaire problemen lineair oplosbaar te maken

Linearisatie (uitwerking)

- Stap 1 & 2: **lineariseren** van onze logit/log(odds)

- Bewijs dat $\ln(\cdot)$ kan gelineariseerd worden: zie addendum

Gegeven:

$$\ln \left(\frac{p(x)}{1 - p(x)} \right) = b_0 + b_1 x$$

- Stap 3: **converteren** log(odds) terug naar probability


- Zie addendum voor uitwerking

(standaardvorm sigmoid)

$$p(x) = \frac{1}{1 + e^{-(b_0 + b_1 x)}}$$

Beperkingen Linearisatie

- Geen Least Squares
- Residuen = oneindig




Verdere problemen Logistische Regressie

- **Geen consensus** over R^2 berekening
 - McFadden, Nagelkerke, Cox-Snell,...
- **Loss functie** van Sigmoid is **niet convex**
 - Meerdere minima
 - Risico op vastzitten in lokaal minimum ipv globaal minimum
- **Geen analytische oplossing**
 - Lineaire Regressie heeft dit wel

Detail Sigmoid & Lineaire Relatie

- Oplossing:
 - Vervang x
 - Door: $a + bx$
- **Decision boundary = a**
 - Waar is curve gecentreerd?
 - Grote a = curve naar links
 - Kleine a = curve naar rechts
- **Slope = b**
 - Steilheid van de curve
 - Grote b = steile curve
 - Kleine b = uitgerekte curve



Maximum Likelihood

- We hebben aantal datapunten waar voor elke waarde x er een y waarde is $\{(x_1, y_1), (x_2, y_2), \dots (x_n, y_n)\}$
- We kunnen de **vorm van de sigmoïde bepalen** omdat we **linearisatie** hebben toegepast
 - Aanpassen a en b in $ax = b$
- We willen onze **sigmoïde** zo goed mogelijk afstemmen zodat we **zoveel mogelijk punten in onze dataset correct classificeren**

Maximum Likelihood

- Bereken **product** van alle **probabiliteiten** in onze dataset (x_i, y_i)
- Pi-notatie = Product
- Itereer over alle (x_i, y_i) in onze dataset en vul in in de functie
- Algoritme zal a en b aanpassen zodat **L geminimaliseerd** wordt
- Algoritme **log**(L) minimaliseren omdat dit makkelijker is
- Toepassing van **Gradient Descent** als algoritme

Fitting Using Maximum Likelihood

$$p(x_i) = \frac{1}{1 + e^{-(a+bx_i)}}$$

$$\Pr(y = y_i | x = x_i) = p(x_i)^{y_i} [1 - p(x_i)]^{1-y_i}$$

$$y_i = 1 \text{ or } 0$$

For n data points the likelihood function:

$$L = \prod_{i=1}^n p(x_i)^{y_i} [1 - p(x_i)]^{1-y_i}$$

Maximum Likelihood

$$L = \prod_{i=1}^n p_i$$

$$\log L = \sum_{i=1}^n \log(p_i)$$


$$L = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}$$

$$\log L = \sum_{i=1}^n [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)]$$

Logistische Regressie (multiple predictors)


GRAFISCHE WEERGAVE VAN LOGISTISCHE REGRESSIE CLASSIFIERS

1 PREDICTOR ($z = b_0 + b_1x$)




- Klasse 1
- Klasse 2
- Classifier
- - - Drempel ($P=0,5$)

2 PREDICTORS ($z = b_0 + b_1x_1 + b_2x_2$)



- Klasse 1
- Klasse 2
- Classifier
- - - Drempel ($P=0,5$)

3 PREDICTORS ($z = b_0 + b_1x_1 + b_2x_2 + b_3x_3$)



Classifier is een plat vlak in de 3D-ruimte.
Ene kant vlak $\rightarrow$ Klasse 1
Andere kant $\rightarrow$ Klasse 2

Gradient Descent

- Klassiek proces
- Vertrek vanuit de **Loss functie**
 - Herinner: Geconverteerd naar Algebraïsche Som via $\log(L)$
- Bereken de **partiële afgeleiden**
- Pas de **parameters a en b** aan via de **learning rate**

Gradient Descent

$$\hat{y} = \sigma(z) = \frac{1}{1 + e^{-z}}$$

$$z = a \cdot x + b$$

$$L(a, b) = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)]$$

$$\frac{\partial L}{\partial a} = (\hat{y} - y) \cdot x$$

$$\frac{\partial L}{\partial b} = (\hat{y} - y)$$

$$a \leftarrow a - \eta \frac{\partial L}{\partial a}$$

$$b \leftarrow b - \eta \frac{\partial L}{\partial b}$$

ML Context

Van theorie naar praktijk

- Van wiskunde naar notebook
- In notebook: dataset van 30.000 credit card houders
- Doel: voorspellen of een klant zijn creditcardrekening zal betalen (*default*)

Dataset: Onbewerkte informatie

- Wat voeden we aan het model?
- Features: inkomen, geslacht, opleiding, leeftijd, betaalgeschiedenis.
- Target (y): 0 (betaalt netjes) of 1 (betaalt niet).

	ID	LIMIT_BAL	SEX	EDUCATION	MARRIAGE	AGE	PAY_0	PAY_2	PAY_3	PAY_4	...	BILL_AMT4	BILL_AMT5	BILL_AMT6	PAY_AMT1	PAY_AMT2	PAY_AMT3	PAY_AMT4	PAY_AMT5	PAY_AMT6	default.payment.next.month
0	1	20000.0	2	2	1	24	2	2	-1	-1	...	0.0	0.0	0.0	0.0	689.0	0.0	0.0	0.0	0.0	1
1	2	120000.0	2	2	2	26	-1	2	0	0	...	3272.0	3455.0	3261.0	0.0	1000.0	1000.0	1000.0	0.0	2000.0	1
2	3	90000.0	2	2	2	34	0	0	0	0	...	14331.0	14948.0	15549.0	1518.0	1500.0	1000.0	1000.0	1000.0	5000.0	0
3	4	50000.0	2	2	1	37	0	0	0	0	...	28314.0	28959.0	29547.0	2000.0	2019.0	1200.0	1100.0	1069.0	1000.0	0
4	5	50000.0	1	2	1	57	-1	0	-1	0	...	20940.0	19146.0	19131.0	2000.0	36681.0	10000.0	9000.0	689.0	679.0	0
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
29995	29996	220000.0	1	3	1	39	0	0	0	0	...	88004.0	31237.0	15980.0	8500.0	20000.0	5003.0	3047.0	5000.0	1000.0	0
29996	29997	150000.0	1	3	2	43	-1	-1	-1	-1	...	8979.0	5190.0	0.0	1837.0	3526.0	8998.0	129.0	0.0	0.0	0
29997	29998	30000.0	1	2	2	37	4	3	2	-1	...	20878.0	20582.0	19357.0	0.0	0.0	22000.0	4200.0	2000.0	3100.0	1
29998	29999	80000.0	1	3	1	41	1	-1	0	0	...	52774.0	11855.0	48944.0	85900.0	3409.0	1178.0	1926.0	52964.0	1804.0	1
29999	30000	50000.0	1	2	1	46	0	0	0	0	...	36535.0	32428.0	15313.0	2078.0	1800.0	1430.0	1000.0	1000.0	1000.0	1

Data Cleansing

- Wiskunde → nette data: ordinaal & nominaal
- Computers kunnen niet rekenen met tekstwaarden
- Wiskundige operaties (zoals matrixvermenigvuldiging) vereisen numerieke input!
- One-hot encoding!
 - Categorische waarde → binaire waarde met eigen kolom
 - Vb.: sex: 1=male, 2=female; maar male<!female


Feature Scaling

- AGE (20-80) vs. LIMIT_BAL (10.000-1.000.000)
- Wiskundig probleem: grote getallen domineren de gradient descent
- Features zitten op Andere schalen
- Oplossing: Z-score normalisatie/standaardisatie
 - Door middel van StandardScaler


Cross-Validation

- Dataset opsplitsen in training- en validatiesets (folds)
- Model telkens trainen op deel van de data
 - Testen op overgebleven deel
- Uiteindelijk: gemiddelde van scores van alle folds
 - → stabielere dan 1 train/test-split (afhankelijk van toeval)
- Overfitting opmerken
- Data lekkage voorkomen

Cross-Validation



⇒ ϵ_{final}



Training: Gradient Descent

- Train_test_split()
- model.fit()
 - Verschillende models
- Maximum Likelihood & Gradient Descent

```
X_train, X_test, y_train, y_test = train_test_split(X, y,
train_size=0.7, random_state=1234) #Set state to be apple to reproduce
values automatically

models = {
    LogisticRegression(): "Logistic Regression",
    SVC(): "Support Vector Machine",
    MLPClassifier(): "Neural Network"
}





for model in models.keys():
    model.fit(X_train, y_train)

/opt/conda/lib/python3.7/site-packages/sklearn/neural_network/
_multilayer_perceptron.py:696: ConvergenceWarning: Stochastic
Optimizer: Maximum iterations (200) reached and the optimization
hasn't converged yet.
  ConvergenceWarning,

for model, name in models.items():
    print(name+ " : {:.2f}%".format(model.score(X_test, y_test)*100))

Logistic Regression: 81.14%
Support Vector Machine: 82.12%
Neural Network: 80.81%
```

Vergelijking!



Is Logistische Regressie de beste keuze?

- Vergelijken:
 - Logistische Regressie: 81.14% accuracy.
 - SVM: 82.12%.
 - Neural Network: 80.81%.
- Accuracy: Hoe weten we of het model echt werkt?
 - Accuracy is misleidend als 90% van de mensen altijd betaalt.
 - We kijken naar de **Confusion Matrix!**

Confusion Matrix

- TP (True Positive):
Correct voorspeld dat iemand niet betaalt
- FP (False Positive): 'Vals alarm'

		Actual Value	
		Positive [have disease]	Negative [no disease]
Predicted Value	Positive [have disease]	TP	FP
	Negative [no disease]	FN	TN

$specificity = \frac{TN}{FP + TN}$

$fall-out = \frac{FP}{FP + TN}$

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

$$\text{Specificity} = \frac{TN}{TN + FP}$$


Sensitivity & Specificity

- De balans vinden tussen goed en kwaad
- Sensitivity: Echte positieve gevallen herkennen
 - Hoeveel van de echte wanbetalers vinden we?
 - Zoveel mogelijk risicovolle klanten opsporen
- Specificity: Echte negatieve gevallen herkennen
 - Hoeveel van de goede betalers laten we onterecht door?
 - Vermijden veilige klanten onterecht als risicovol zien
- Accuracy = hoeveel juist raden?
 - niet welke soorten fouten

ROC & AUC: De Area Under the Curve

- ROC: onderscheid maken tussen TP en FP
 - Hoe hoger de boog, hoe beter het model onderscheid kan maken
- AUC: vat curve samen in 1 getal
 - Hoe groter AUC, hoe beter model onderscheid maakt

AUC score: 0.732



Is Logistische Regressie de beste keuze?

- Accuracy vergelijken:
 - Logistische Regressie: 81.14%
 - SVM: 82.12%
 - Neural Network: 80.81%
- Log Reg: interpreteerbaar & uitlegbaar
 - Geeft klasse en kans

Sterktes

- Waarom Logistische Regressie?
- **Snelheid:** Zeer efficiënt voor grote datasets
- **Interpreteerbaarheid:** We kunnen precies zien welke factor (bv. AGE) de kans het meeste beïnvloedt via de coëfficiënten
- **Probabiliteit:** Het geeft niet alleen 'ja/nee', maar een kanspercentage (bv. 85% kans op default)

Zwaktes

- **Lineariteit:** Het model gaat ervan uit dat de log-odds een rechte lijn vormen → als de relatie complexer is, faalt het model
- **Outliers:** Gevoelig voor extreme uitschieters (hoewel minder dan lineaire regressie)
- **Onafhankelijkheid:** Het model gaat ervan uit dat de variabelen niet al te sterk met elkaar gecorreleerd zijn

Wat hebben we geleerd?

- Hoe abstracte calculus (sigmoids, afgeleiden) direct vertaalt naar financiële beslissingen
- Het belang van data-preprocessing (scaling/encoding) voordat de wiskunde kan werken
- Hoe belangrijk cross-validatie is voor een goed model
- Dat 'accuracy' niet de enige maatstaf is voor succes

Conclusie

- Logistische regressie is een fundament van classificatie
- Wiskundige parameters (a, b, c) bepalen de nauwkeurigheid
- Cruciaal instrument voor elke IT-professional in Data Science

Vragen?

Resources

- Logistische Regressie
 - StatQuest (https://statquest.org/video_index.html)
 - Odds and Log(odds)
 - Logistic Regression
 - Logistic Regression, Details 1: Coefficients
 - Logistic Regression, Details 2: Maximum Likelihood
 - Logistic Regression, Details 3: R-squared & p-value
 - Introduction to Machine Learning - 05 - Logistic regression (University of Tübingen)
 - <https://www.youtube.com/watch?v=cGUjiHyQWPk&list=PLOiV4VBtoy5X3Y56Hg3L-FDiXOguLBiYq&index=69>
 - NPTEL IIT Guwahati Lecture 35: Logistic Regression
 - https://www.youtube.com/watch?v=d_bynTkE9yY&list=PLOiV4VBtoy5X3Y56Hg3L-FDiXOguLBiYq&index=68
 - MathWorks: Cross-Validation
 - <https://nl.mathworks.com/discovery/cross-validation.html>
 - ML Concepts: Classification: ROC and AUC
 - <https://developers.google.com/machine-learning/crash-course/classification/roc-and-auc/>
 - How to explain the ROC curve and ROC AUC score?
 - <https://www.evidentlyai.com/classification-metrics/explain-roc-curve>
 - AI/LLM
 - ChatGPT & Gemini